

 2023143027 / mobilebert-toxic-detection

Q Type to search

<> Code Issues Pull requests Actions Projects Wiki Security and quality Insights Settings

mobilebert-toxic-detection / README.md

2023143027 Update README.md

Ocea324 · last week History

Preview Code Blame 87 lines (56 loc) · 5.9 KB

Raw Copy Download Edit

댓글 데이터를 활용한 악성 댓글 멀티 라벨 분류 분석

1. 프로젝트 개요

- 배경 및 필요성:** 온라인 커뮤니티의 익명성을 악용한 유해 댓글이 심각한 정서적 스트레스와 갈등을 유발함. 이를 자동으로 필터링할 수 있는 시스템이 필요하다고 생각함.
- 동기:** 평소 인터넷 댓글의 악성 분류 기준이 궁금했으며, 수업 시간에 배운 MobileBERT 문장 분류 모델을 실제 데이터셋에 직접 적용해보고 성능을 확인하고자 시작함.
- 방향 전환 이유:** 실제 댓글 창은 단순 정상/악성 분류를 넘어 욕설, 모욕, 혐오 표현 등이 복합적으로 얹혀 있음. 이를 정밀하게 필터링하기 위해 6가지 유해 속성을 동시에 잡아내는 '멀티 라벨 분류' 방식으로 설계함.

2. 원본 데이터 수집 및 탐색적 데이터 분석 (EDA)

- 데이터 출처:** Kaggle 'Toxic Comment Classification Challenge' 공개 데이터셋 (`train.csv`)
- 수집 규모:** 총 159,571건의 대용량 웹 댓글 코퍼스 확보 (용량 문제로 깃허브에는 상위 일부 샘플만 추출하여 업로드 예정).
- 원본 데이터 EDA 결과:** 악성 라벨이 없는 정상 댓글이 전체의 약 90%를 차지하는 극심한 데이터 편향을 보임. 특정 유해 범주(협박, 정체성 혐오 등)는 발생 비율이 1% 미만인 불균형 상태를 확인함.

3. 원본 데이터 전처리 및 분석 대상 데이터 구축

- 결측치 정제:** 유효하지 않은 빈 데이터 행을 `.dropna()` 로직으로 사전 제거함.
- 칼럼 정렬:** `comment_text` 와 6개 타겟 라벨 칼럼만 슬라이싱하여 정형화함.
- 문장 길이 제한:** 하드웨어 VRAM 연산 자원을 고려하여 최대 토큰 길이를 128로 제약함.
- 분석 대상 데이터 정의:** 전처리가 완료된 코퍼스 중 상위 35,000건을 추출하고, 이를 최종 "분석 대상 데이터"로 명명함.

4. 학습 데이터 추출 및 라벨링 분석


4.1 학습 데이터 추출 과정 명시

수업 지침인 2,000~3,000건 규모의 데이터 추출을 검토했으나, 경량 모델인 MobileBERT의 문맥 가중치 학습 효율을 극대화하기 위해 분석 대상 데이터 (35,000건)의 80%인 28,000건을 최종 미세조정용 ***학습 데이터***로 가용 범위를 확장하여 명시함.

4.2 학습 데이터 라벨링 과정 및 결과 분석

추출된 학습 데이터는 6가지 유해 속성의 존재 여부가 이진 행렬(0과 1)로 마킹되는 다중 라벨링 구조를 가짐. 라벨별 정량 통계 수치는 다음과 같음.

라벨명 (악성 범주)	학습 데이터 내 발견 건수 (건)	학습 데이터 내 실제 비율 (%)
toxic (일반 악성)	3,427건	9.79%
severe_toxic (심각한 악성)	356건	1.02%
obscene (외설/비속어)	1,856건	5.30%
threat (협박)	115건	0.33%
insult (모욕)	1,732건	4.95%
identity_hate (정체성 혐오)	310건	0.89%




- 결과 분석: 추출 결과 `toxic(일반 악성)` (9.79%) 비율이 가장 높고 `threat()` (0.33%) 비율이 가장 낮아, 원본 데이터의 온라인 불균형 특성이 그대로 유지되었음을 확인함.

5. MobileBERT 모델 학습 결과

5.1 에포크별 훈련 로그 수치

- Epoch 1: 학습 오차 = 0.4512 | 학습 정확도 = 0.9853 | 검증 정확도 = 0.9827
- Epoch 2: 학습 오차 = 0.0469 | 학습 정확도 = 0.9887 | 검증 정확도 = 0.9832
- Epoch 3: 학습 오차 = 0.0335 | 학습 정확도 = 0.9902 | 검증 정확도 = 0.9834

5.2 시각화 차트 분석



- 그래프 해석: 에포크 진행에 따라 손실 오차가 바닥에 안정적으로 수렴함. 학습 정확도와 검증 정확도 모두 큰 격차 없이 정답률 98%대에서 나란히 우상향하여 안정적인 미세조정이 완료되었음을 증명함.

6. 문제제기에 대한 결과 및 실전 추론 시뮬레이션

서론에서 제기한 복합 악성 댓글 분류 및 자연어 처리 모델의 활용 가능성을 확인하기 위해, 독립 예측 모듈(`predict.py`)을 통해 임계값 0.5 기준으로 4가지 가상 시나리오 추론 테스트를 수행함.

6.1 시나리오 문장별 다중 라벨 탐지 확률 결과

- 시나리오 1 (정상 표현): "Hey, that is a really good point!..." -> 정상 (Clean) (모든 라벨 0.5 미만)
- 시나리오 2 (비속어 및 모욕): "You are so stupid and idiot..." -> toxic (100.0%), insult (99.3%), obscene (68.2%) 다중 탐지 완료
- 시나리오 3 (물리적 협박): "I will find you and I will hurt you badly..." -> toxic (97.2%), threat (81.3%) 동시 탐지 완료

- 시나리오 4 (혐오 발화): "This disgusting person belongs to a trash group..." -> `toxic` (99.7%), `insult` (82.6%), `obscene` (77.7%), `identity_hate` (53.0%) 복합 탐지 완료

6.2 서론 문제제기에 대한 결론 도출

- 최종 결론: 최종 검증 정확도 **98.34%**로 합격 기준선(0.85)을 통과하며 모델의 유효성을 확인함.
- 실전 추론 결과, 원본 데이터셋에서 샘플 수가 극도로 부족했던 소수 라벨인 협박(`threat` , 81.3%)과 정체성 혐오(`identity_hate` , 53.0%) 패턴을 정확하게 식별하여 다중 라벨을 동시 활성화함. 모델이 다수파 데이터에 편향되지 않고 고유의
- 언어적 속성을 균형 있게 학습했음을 보여주며, 단순 유해 차단을 넘어 구체적인 유해성 죄질을 복합 분리하겠다는 프로젝트 목적을 달성함.